계층 강화학습 기반의 차량 네트워크에서의 딜레이-민감 비디오 전달 시스템

김유노, 상천가, *김영진, 최민석

경희대학교, 인하대학교*

rladbsh456@naver.com, singskyx@khu.ac.kr, yj.kim@inha.ac.kr*, choims@khu.ac.kr

Hierarchical Reinforcement Learning-Based Delay-Sensitive Video Delivery in Vehicular Networks

Yunoh Kim, Tiange Xiang, *Yeongjin Kim, Minseok Choi

Kyung Hee Univ., Inha Univ.*

요 약

본 논문에서는 Deep Q Network(DQN) 알고리즘을 이용하여 딜레이에 민감한 동적 비디오 스트리밍에서의 비디오 조각 전송을 조절한다. 또한, chunk 전송을 위한 스케쥴링에서도 보다 좋은 캐싱 노드를 선택하여 더 높은 비트율과 더 적은 재생 지연 발생율을 보장할 필요성이 있다. 따라서 어떤 캐싱 노드와 스케쥴링 하는지에 대한 결정에도 DQN을 이용한다. 위 두 가지 강화학습 모델이 계층적으로 동작하면서 비디오 스트리밍 사용자에게 더 적은 재생 지연 발생율과 더 높은 비트율을 제공하는 기술을 제안한다.

Ⅰ. 서 론

온라인 비디오 서비스는 전체 데이터 트래픽 중 가장 많은 비율을 차지하고, 그중 동적 비디오 스트리밍 사용자 수는 급증하고 있다 [1]. 또한 최근에는 스마트기기의 보급으로 차량 운전자와 승객에게서도 비디오 서비스에 대한 수요가 증가하고 있다 [2]. 따라서 차량 네트워크에서도 효율적으로 비디오 스트리밍 서비스를 제공하는 방법이 필요하다.

차량 네트워크에서는 사용자의 이동성 때문에 통신환경에 대한 변화가 잦다. 따라서 환경에 따라 동적으로 동작할 수 있는 합리적인 방법이 필요하고, 이를 위해 본 논문에서는 강화학습 알고리즘을 사용하고자 한다. 강화학습을 사용한 비디오 전달 [3]과 스케쥴링 [4]에 대한 연구는 존재하지만, 이는 두 과정을 분리한 연구들이다. 또한, 스케쥴링에 사용자의 큐잉 시스템 정보를 사용하지 않았기 때문에 스케쥴링에도 사용자의 큐잉시스템을 반영하여 실질적인 재생 지연율을 줄이기 위한 연구가 필요하다. 따라서 본 논문에서는 사용자의 큐잉시스템을 파악하여 스케쥴링 및 비디오 전달에 계층적으로 동작하는 강화학습 알고리즘을 제안하고자 한다.

Ⅱ. 차량 네트워크에서의 딜레이-민감 비디오 스트리밍 시스템

본 연구에서는 차량 네트워크 내 분포된 캐싱 노드에 비디오 콘텐츠가 캐싱되어 있을 때, 움직이는 사용자가 딜레이-민감 비디오 서비스를 요청하는 시스템을 고려한다. 타겟 사용자는 반경 R내 위치한 캐싱 노드에게만 파일을 받을 수 있고, 해당 노드의 수는 $N(t)$라 하자. 모든 노드는 주어진 공간에 푸아송 프로세스에 따라 분포되어 있다. 각 노드는 Scalable Video Coding(SVC)로 인코딩된 비디오를 캐싱하는데, 비디오 파일은 짧은 재생 시간을 담당하는 여러 chunk로 구성되고 SVC로 인코딩된 비디오의 각 chunk는 L개의 레이어로 구성된다. 각 chunk는 최소 하나의 기저 레이어가 송신되어야 재생 가능하며, 여러 레이어가 송신될수록 높은 비트율을 제공할 수 있다. 각 노드는 요청된 비디오의 모든 chunk를 캐싱하지만 캐싱된 비트율(레이어 개수)은 다르다고 가정한다.

시간이 $t \in \{0,1,\cdots\}$로 이산적으로 슬롯화 되었을 때, 사용자는 비디오를 수신할 캐싱 노드 $\alpha(t)$를 선택하고, 받고자 하는 chunk의 개수 $M(t)$와 레이어 수 $K(t)$를 결정한다. 시간 t에 보내는 모든 chunk의 레이어 수는 같다고 가정한다. Rayleigh fading 채널 모델을 가정하였을 때 채널 용량은 $C(t) = W\log_2(1+\frac{\Psi|h(t)|^2}{\Upsilon+1})$이며, $h(t)=\sqrt{\frac{w(t)}{d^\beta}}u(t)$은 채널 게인, $u(t) \sim CN(0,1)$는 빠른 페이딩 게인, $w(t) \sim N(0,1)$는 섀도잉 효과, d는 송수신 거리, β는 경로 손실 계수, Υ는 INR, W는 대역폭, Ψ는 전송 신호대잡음비(SNR)이다. t_c가 chunk 재생 시간일 때, 채널 용량에 따라 $M(t)$와 $K(t)$의 조합은 (1)과 같이 제한된다.

$$M(t) \cdot K(t) \le t_c C(t)) \tag{1}$$

전송된 chunk들은 사용자 큐에 쌓여 재생되기를 기다리고, 매 시간 1개의 chunk가 재생된다고 하자. 시간 t에서 큐 길이가 $Q(t)$일 때, 큐 길이 업데이트 식은 (2)와 같다.

$$Q(t+1) = \max(\mathrm{Q(t)-1,0})+\mathrm{M(t)} \tag{2}$$

이때, $Q(t)=0$이라면 재생할 chunk가 없으므로 재생 지연이 발생한다. (1)에 의해 $M(t)$를 증가시키면 $K(t)$를 줄여야 하기 때문에 비디오의 비트율과 재생 지연 사이에 트레이드오프가 발생한다. 본 연구에서는 이러한 트레이드오프를 조절하는 DQN 기반 스트리밍 방식을 제안한다. 캐싱 노드 스케쥴링에서도 높은 비트율로 컨텐츠를 전송받기 위해서는 많은 레이어로 캐싱한 노드와 스케쥴링하는 것이 좋지만, 많은 chunk를 수신하여 재생 지연을 방지하려면 거리가 가까운 노드를 선택하는 것이 좋다.

전송하려는 비디오 chunk의 비트율과 개수의 선택에 비해 캐싱 노드 스케쥴링은 시간이 필요한 작업으로, 에이전트의 행동 결정을 내리는 시간 스케일이 다르다. 본 논문에서는 전송하는 chunk의 개수 $M(t)$와 레이어 개수 $K(t)$은 빠른 시간 스케일로 결정하고, 캐싱 노드 선택 $\alpha(t)$은 느린 시간 스케일로 하는 계층 강화학습 알고리즘을 고안한다.

Ⅲ. 계층적 강화학습

DQN이란 강화학습 알고리즘 중 하나로, 입력받은 상태에 따라 에이전트가 행동 가치 값을 기준으로 가장 가치 있는 행동을 판단하여 결정하는 알고리즘이다. 강화학습에서 에이전트는 누적된 보상 합이 최대화가 되도

록 학습하기 때문에 목적에 맞는 보상함수를 설정해야 한다.

비디오 chunk를 전송하는 짧은 시간 단위에서 동작하는 DQN 모델은 현재 큐에 쌓인 chunk 개수 $Q(t)$와 직전의 비트율을 의미하는 K_l값을 입력으로 받아 $M(t)$, $K(t)$를 결정한다. 보상함수 $R_s(t)$는 재생 끊김 현상을 줄이고, 수신 chunk의 개수는 증가시키고, 높은 비트율을 수신하기 위해 많은 레이어를 받고, 사용자 만족도를 위해 비트율 변화 폭을 제한하고자 식 (3)과 같이 설계하였다.

$$R_s(t) = k_1\sqrt{M(t)} + k_2 K(t) - k_3 I\{Q(t)=0\} - k_4 |K_l - K_p| \quad (3)$$

식 (3)에서 k_1, k_2, k_3, k_4는 각각 많은 chunk의 수신, 높은 비트율 추구, 재생 끊김 현상 방지, 비트율 변화 폭 제한을 위한 가중치를 의미한다.

캐싱 노드의 스케쥴링 결정을 긴 시간 단위로 내리는 DQN 모델은 노드 $\alpha(t)$를 스케쥴링 하였을 때 다음 스케쥴링 이전까지 비디오 chunk 전송으로 얻을 수 있는 보상 값의 합인 식 (4)로 보상함수를 정의한다.

$$R_{\alpha(t)}(nT_c) = \sum_{t=nT_c}^{(n+1)T_c-1} R_s(t) \quad (4)$$

이로 인해 비디오 chunk 전송 에이전트의 성능이 좋아지는 방향으로 스케쥴링 에이전트 또한 학습하게 된다.

이처럼 두 가지 시간 단위에 대해 행동 결정이 필요하고 의존적인 행동 결정이 존재할 경우, 계층적인 강화학습을 통해 두 가지 행동 결정이 모두 좋은 결과를 가지고 오는 방향으로 학습시킬 수 있다.

Ⅳ. 실험 결과

제안한 계층 강화학습 기술의 성능 평가를 위해 두 가지의 다른 노드 스케쥴링 비교 기술을 채택하였다. 첫 번째는 최대한 많은 chunk를 수신하여 재생 멈춤을 방지하기 위해 항상 가장 가까운 캐싱 노드를 스케쥴링하는 'distance', 두 번째는 높은 비트율을 추구하기 위해 항상 가장 높은 비트율의 파일을 캐싱한 노드를 스케쥴링 하는 'quality'를 이용하였다.

Fig.1-2에서는 캐싱 노드의 퀄리티 분포 확률에 따른 성능을 보인다. 3개의 비트율 $L=3$이 있을 때, case 1에서는 캐싱 퀄리티가 낮은 노드의 분포 확률이 크고, case 3에서는 캐싱 퀄리티가 높은 노드의 분포 확률이 크며, case 2에서는 모든 캐싱 퀄리티의 노드 분포 확률이 동일하다. 높은 비트율의 파일을 가진 노드가 많을수록 비트율이 높아지고 재생 멈춤 현상이 적게 발생한다. 또한, 계층 강화학습을 통해 'quality' 대비 재생 멈춤 현상을 적당히 제한하면서 'distance' 대비 비트율을 개선할 수 있다.

Fig.3-4는 매 에피소드마다 노드의 퀄리티 분포 확률이 다른 경우, SNR에 대한 성능을 나타낸 그래프이다. SNR이 좋아질수록 높은 비트율과 낮은 재생 멈춤 발생률을 보인다. 이전 Fig.1-2에서와 같이 'quality' 대비 낮은 재생 멈춤 발생률과 'distance' 대비 높은 비트율을 확인할 수 있다. Table 1은 노드의 분포가 case 1일 때 수신 chunk의 비트율 변화가 두 단계 이상인 경우의 발생율을 나타낸 표이다. 제안한 기술이 굉장히 낮은 비트율 변화 폭을 보인다고 할 수 있다.

본 논문에서 제안한 계층 강화학습 기반의 차량 네트워크에서의 비디오 전달 기술은 위와 같이 비트율 변화 폭을 제한하면서 평균 비트율과 재생 멈춤 발생 간의 트레이드오프를 조절할 수 있었다. 이때, 보상함수의 가중치 값을 조절하면서 원하는 타겟 비트율 또는 타겟 재생 멈춤 발생률에 맞추어서 성능을 조절할 수 있는 장점이 있음을 덧붙인다.

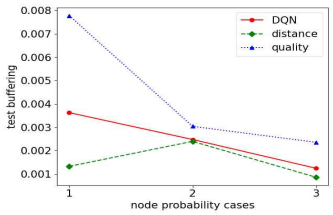

Fig.1 노드 분포 별 재생 멈춤 발생률

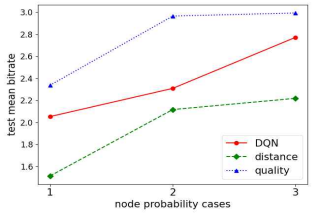

Fig.2 노드 분포 별 평균 비트율

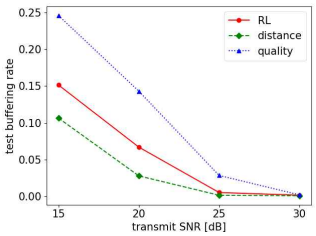

Fig.3 SNR 별 재생 멈춤 발생률

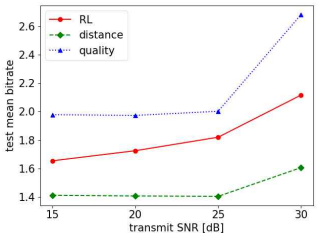

Fig.4 SNR 별 평균 비트율

SNR[dB]	15	20	25	30
Fluctuation Rate	0.00141	0.00155	0.00217	0.02340

Table.1 SNR별 평균 비트율 변화량

Ⅴ. 결론

본 논문에서는 사용자 이동성이 있는 경우, 계층적 강화학습을 이용한 비디오 스트리밍 서비스의 비트율 및 재생 지연에 대한 성능을 높이고, 비트율 변화를 줄이는 방법을 제안한다. 이를 통해 거리 및 캐싱 퀄리티에 대한 결정론적 스케쥴링 방법의 단점을 완화하는 성능을 확인할 수 있었다.

ACKNOWLEDGMENT

This work was supported in part by Institute of Information & communications Technology Planning & Evaluation (IITP) grant funded by the Korea government(MSIT) (No.2021-0-02201), and in part by the National Research Foundation of Korea(NRF) grant funded by the Korea govenment(MSIT) (NRF-2022R1C1C1010766, NRF-2022R1A4A3033401).

참 고 문 헌

[1] Cisco, "Cisco visual networking index: Global mobile data traffic forecast update, 2017-2022 White Paper," 2019.

[2] Y. Guo, Q. Yang, F. R. Yu and V. C. M. Leung, "Cache-Enabled Adaptive Video Streaming Over Vehicular Networks: A Dynamic Approach," in IEEE Transactions on Vehicular Technology, vol. 67, no. 6, pp. 5445-5459, June 2018, doi: 10.1109/TVT.2018.2817210.

[3] Yunoh Kim, Hyeonsoo Kim, Seunghoon Oh, and Minseok Choi, "A Study on Deep Q-Network Algorithm for Delay-Sensitive Video Streaming Service," in Proceedings of Symposium of the Korean Institute of communications and Information Sciences, 2023, pp. 1090-1091

[4] R. F. Atallah, C. M. Assi and M. J. Khabbaz, "Scheduling the Operation of a Connected Vehicular Network Using Deep Reinforcement Learning," in IEEE Transactions on Intelligent Transportation Systems, vol. 20, no. 5, pp. 1669-1682, May 2019, doi: 10.1109/TITS.2018.2832219.